

Introduction à l'Intelligence Artificielle (IA)
et à l'Apprentissage Machine (ML)
pour lycéen(ne)s



Par Noé Dia.

Contents

1	Notions mathématiques pour l'IA.	3
1.1	Algèbre linéaire et calcul matriciel	3
1.1.1	Opérations matricielles	3
1.1.2	Trace d'une matrice	3
1.1.3	Déterminant d'une matrice	3
1.1.4	Résolution d'un système d'équations linéaire	3
1.2	Calcul à plusieurs variables	3
1.2.1	La dérivée en 3D et hautes dimensions: l'opérateur gradient	3
1.2.2	L'intégrale en 3D et hautes dimensions	3
1.3	Théorie des Probabilités et Statistiques	3
1.3.1	Fréquentisme ou Bayésianisme, telle est la question...	3
1.3.2	Expériences aléatoires et définition des probabilités	4
1.3.3	Probabilités discrètes	4
1.3.4	Moyenne et déviation standard d'une distribution de probabilité discrète	5
1.3.5	Exemples de lois de probabilité discrètes	6
1.4	Probabilités continues.	6
1.4.1	Probabilités jointes, conditionnelles et théorème de Bayes	6
1.4.2	Quelques distributions de probabilités de base...	6
1.4.3	Visions philosophiques Bayésienne des statistiques.	6
1.5	Théorie de l'Information	6
2	Notions de programmation en Python pour l'IA.	7
2.1	Notation	7
2.2	Installer Python	7
2.2.1	Google Collab (recommandé)	7
2.2.2	Installer Python via VS code (recommandé)	7
2.2.3	Installer Python via Anaconda	8
2.2.4	Environnement virtuel	8
2.3	Bonus: Customiser VS Code avec des Plugins.	8
2.4	Notions de base en Python	8
2.4.1	Les différents types de variables et les opérations en Python	8
2.4.2	Les conditions <code>if</code> , <code>elif</code> et <code>else</code>	8
2.4.3	Les boucles <code>for</code> et <code>while</code>	8
2.4.4	Données tabulées et Figures avec <code>numpy</code> et <code>matplotlib</code>	8
3	Intelligence Artificielle,	8
3.1	Histoire de l'IA	8
3.2	Fondements de l'apprentissage machine	8
3.2.1	Théoreme d'approximation universelle ou Théoreme de Cybenko: le pilier fondateur de l'apprentissage profond	8
3.2.2	Réseaux de neurones comme machines à apprendre des fonctions	8
3.2.3	Entraînement de réseaux de neurones: maximisation de la vraisem- blance.	8
3.2.4	Régularisation et Hyperparameter tuning pour éviter le sur-ajustement et le sous-ajustement	8

4	Mini-projets	9
4.1	Simulation d'un double pendule	9
5	Projets	9
5.1	Inférence bayésienne d'images avec modèles de diffusion	9
5.2	Inférence bayésienne d'images avec normalizing flows	9
5.3	Transport optimal avec interpolant stochastique.	9
5.4	Apprentissage de distribution a priori sur Lénia	9

1 Notions mathématiques pour l'IA.

1.1 Algèbre linéaire et calcul matriciel

1.1.1 Opérations matricielles

1.1.2 Trace d'une matrice

1.1.3 Déterminant d'une matrice

1.1.4 Résolution d'un système d'équations linéaire

Algorithme de Gauss-Jordan.

1.2 Calcul à plusieurs variables

1.2.1 La dérivée en 3D et hautes dimensions: l'opérateur gradient

exemple de calcul du gradient d'une fonction à 2 variables. Exemple de trouver points de selle, maxima et minima.

1.2.2 L'intégrale en 3D et hautes dimensions

Changement de variables dans l'intégrale avec Jacobien.

1.3 Théorie des Probabilités et Statistiques

1.3.1 Fréquentisme ou Bayésianisme, telle est la question...

Afin de parler statistiques, nous devons inévitablement définir clairement la notion de *probabilité*. Il existe deux définitions associées à deux écoles de pensée: le fréquentisme et le bayésianisme.

Dans la vision fréquentiste, une probabilité est définie comme la fréquence à long-terme d'événements qui peuvent se produire plusieurs fois. C'est la définition des probabilités que vous avez apprise au lycée en seconde ou en première. En gros, adopter cette vision, c'est dire: "Si je répète une expérience aléatoire N fois avec N qui tend vers l'infini ($N \rightarrow \infty$), combien de fois j'obtiendrai l'événement X ".

La seconde perspective (ma préférée) est la vision bayésienne des probabilités. Dans cette vision, la probabilité est définie pour déterminer notre incertitude, notre ignorance sur quelque chose. Prenons un exemple. Disons que je veux connaître mon incertitude sur la météo qu'il y aura demain le 26/09

1.3.2 Expériences aléatoires et définition des probabilités

Definition 1.1: Expérience aléatoire, événement

La notion de probabilité va survenir lorsqu'on considérera une expérience aléatoire.

Une expérience aléatoire est une expérience dont les résultats possibles sont connus mais dont le résultat final est dû au hasard.

Un événement correspond à un des différents résultats possibles à l'issue d'une expérience aléatoire.

On peut voir une probabilité comme une fonction qui va prendre en entrée un événement X et qui va donner en sortie un nombre réel entre 0 et 1 qui correspond à la possibilité que l'événement X se réalise. Plus le nombre est proche de 1 plus il y a de chances que l'événement se réalise. L'événement a donc une probabilité élevée de se réaliser. Lorsque le nombre est proche de 0, l'événement a une probabilité faible de se produire.

Exemple 1.1: Expérience aléatoire et événement

On rencontre des expériences aléatoires absolument partout dans notre quotidien sans vraiment s'en rendre compte. Certaines expériences aléatoires font intervenir des probabilités dites discrètes: le jet d'un dé, le lancer d'une pièce... D'autres font intervenir des probabilités dites continues. Elles permettent aussi de poser des questions telles que: (i) quelle est la probabilité que la durée de vie d'un smartphone soit inférieure à deux ans ? (ii) quelle est la probabilité que mon sachet de pâtes fasse (200 ± 10) g ? (iii) quelle est la probabilité que deux élèves d'une classe de 30 aient la même date d'anniversaire ? Un petit exemple tiré de ma propre recherche: Lorsqu'une expérience aléatoire font intervenir une loi de probabilité connue, on dit que l'expérience aléatoire *suit* la loi de probabilité. Par exemple, le lancer d'un dé suit une loi uniforme.

Exemple: La fonction $f(x) = x^2$ prend en entrée une valeur de $x \in \mathbb{R}$ et donne en sortie une valeur $y = x^2$ où $y \in \mathbb{R}$.

On va faire la distinction entre deux types de probabilité,

- Les probabilités discrètes, celles qu'on utilise pour décrire des expériences aléatoires telles qu'un lancer de dé, un lancer de pièce, jouer à pierre-feuille-ciseaux...
- les probabilités continues celles qu'on utilise pour estimer la probabilité que la durée de vie d'un smartphone soit inférieure à 2 ans, ou encore la probabilité qu'une intelligence artificielle nous annihile tous entre 2026 et 2036 etc...

et .

1.3.3 Probabilités discrètes

Dans le cadre des probabilités discrètes, on va considérer une *expérience aléatoire*, c'est-à-dire une expérience dont les résultats possibles sont connus mais dont le résultat final est dû au hasard. Un exemple que vous avez sûrement étudié par le passé est le jet d'un dé. Il existe 6 résultats possibles lors d'un jet de dés mais une fois que le dé est lancé, dur de savoir quelle face du dé nous fera face ;). On appellera *événement* les différents résultats possibles de l'expérience aléatoire. L'ensemble des événements sera noté Ω , aussi appelé

espace d'échantillonnage (“sample space” en anglais). Dans le cadre de notre lancer de dé, l'espace d'échantillonnage peut être écrit,

$$\Omega = \{A, B, C, D, E, F\}, \quad (1)$$

et les différents événements A, B, C, D, E, F correspondent aux résultats possibles suivants,

$$A = \text{Obtenir la face “1”}, \quad (2)$$

$$B = \text{Obtenir la face “2”}, \quad (3)$$

$$C = \text{Obtenir la face “3”}, \quad (4)$$

$$D = \text{Obtenir la face “4”}, \quad (5)$$

$$E = \text{Obtenir la face “5”}, \quad (6)$$

$$F = \text{Obtenir la face “6”}. \quad (7)$$

Pour les probabilités discrètes, on notera $P(\cdot)$ la fonction qui prend en entrée un événement X et qui donne en sortie la probabilité que cet événement se produise. Cette fonction est nommée la *fonction de probabilité de masse*¹.

Pour notre jet de dé, on a

$$P(A) = P(B) = \dots = P(F) = \frac{1}{6} \quad (8)$$

On peut visualiser ça graphiquement Figure ...

Lorsque tous les événements de l'espace d'échantillonnage ont la même probabilité, on dit alors que l'expérience aléatoire suit une *loi de probabilité uniforme* ou simplement *loi uniforme*. Lorsqu'une pmf est constante pour tout événement, on notera

$$P(X) = \mathcal{U}(X). \quad (9)$$

où $\mathcal{U}(X)$ est une fonction constante, i.e.

$$\mathcal{U}(X) = \frac{1}{|\Omega|} = \text{cste} \quad \forall X \in \Omega \quad (10)$$

où $|\Omega|$ dénote la cardinalité de l'espace d'échantillonnage Ω . La cardinalité correspond au nombre d'éléments composant l'ensemble Ω . Dans notre exemple du lancer de dé, on dit que l'espace d'échantillonnage est fini² et qu'il a une cardinalité égale à 6, i.e. $|\Omega| = 6$.

1.3.4 Moyenne et déviation standard d'une distribution de probabilité discrète

Pour des distributions de probabilité (discrètes ou continues), il sera intéressant d'étudier la moyenne et la déviation standard d'une distribution de probabilité.

Admettons une expérience aléatoire qui a été faite un nombre N de fois. Disons par exemple qu'on a lancé N fois un dé. On veut maintenant savoir sur quelle face le dé tombe en moyenne.

¹Ce nom provient de la physique où l'on appelle masse les objets ponctuels sans volume et où l'on va parler de densité lorsqu'un objet avec une forme, un volume occupe un espace. On verra que, lorsqu'on parle de probabilités continues, l'équivalent de la fonction de probabilité de masse est la fonction de probabilité de densité.

²tout simplement parce qu'on peut compter le nombre d'éléments de l'espace d'échantillonnage

Definition 1.2: Moyenne et écart-type d'une distribution de probabilité discrète

La formule générale pour calculer la moyenne d'une probabilité discrète est donnée par,

$$\mu(X) = \mathbb{E}(X) \equiv \frac{1}{N} \sum_{i=1}^N x_i P(X = x_i). \quad (11)$$

où $X \in \Omega = \{x_1, x_2, x_3, x_4, x_5, x_6\} = \{1, 2, 3, 4, 5, 6\}$.

La moyenne n'est pas à confondre avec la médiane ou encore le mode d'une distribution de probabilité. La médiane est le point milieu d'une séquence de données telle que 50% des données ont une valeur inférieure et 50% ont une valeur supérieure.

La formule générale pour calculer l'écart-type d'une probabilité discrète est définie à partir de la moyenne comme,

$$\sigma(X) \equiv \sqrt{\text{Var}(X)} = \sqrt{\mathbb{E}[(X - \mathbb{E}[X])^2]} \quad (12)$$

$$= \sqrt{\mathbb{E}[X^2] - \mathbb{E}[X]^2} \quad (13)$$

$$= \sqrt{\frac{1}{N} \sum_{i=1}^N P(X = x_i)(x_i - \mu)^2} \quad (14)$$

La déviation standard va être une mesure de la dispersion de la distribution de probabilité (à quel point elle s'étale).

Exemple 1.2: Moyenne et déviation standard pour 10 lancers de dé

1.3.5 Exemples de lois de probabilité discrètes

Uniforme Binomial

1.4 Probabilités continues.

On peut également assigner une densité de probabilité à des vecteurs. Par exemple, si je note, $p(\mathbf{x})$

Notez qu'on peut unifier les probabilités discrètes et les probabilités continues avec la *théorie de la mesure*. Vous verrez ceci dans vos études supérieures si vous continuez sur ce chemin-là en mathématiques et/ou en intelligence artificielle. On pourra en discuter brièvement si certain(e)s d'entre vous sont vraiment intéressé(e)s.

1.4.1 Probabilités jointes, conditionnelles et théorème de Bayes

1.4.2 Quelques distributions de probabilités de base...

•

1.4.3 Visions philosophiques Bayésienne des statistiques.

1.5 Théorie de l'Information

2 Notions de programmation en Python pour l'IA.

2.1 Notation

En termes de notation, les variables de programmation seront écrites en Monocode, c'est-à-dire, **comme ça**. J'utiliserai parfois ce qu'on appelle du pseudo-code, c'est-à-dire une version simplifiée d'un programme. Voir l'exemple ci-dessous

Algorithm 1 Exemple d'algorithme

Require: $n \geq 0$

$N \leftarrow n$

while $N \neq 0$ **do**

if N is even **then**

$N \leftarrow \frac{N}{2}$

▷ This is a comment

else if N is odd **then**

$y \leftarrow y \times X$

end if

end while

2.2 Installer Python

2.2.1 Google Collab (recommandé)

Google Collab permet de créer des programmes en Python interactifs (ce qu'on appelle des *notebooks*) sur une machine à distance. Cela va être très utile pour nous une fois qu'on voudra utiliser des machines plus performantes pour entraîner nos modèles d'intelligence artificielle.

Si vous n'avez pas d'ordinateur portables et utilisez l'ordinateur du laboratoire, je vous invite à utiliser Google Collab.

2.2.2 Installer Python via VS code (recommandé)

VS Code est un éditeur de code très populaire et pratique aussi bien pour les professionnels que pour les néophytes. Spécifiquement, on parle d'Environnement de Développement Intégré (en anglais *Integrated Development Environment* ou IDE) lorsqu'on parle de logiciels tels que VS Code, PyCharm etc... Voici certains avantages forts qui font de VS Code un IDE particulièrement attractif:

- ♥ VS Code ne se limite pas à un seul langage. C'est un éditeur de code avec lequel on peut travailler pour la majorité des langages de programmations. Que ce soit du C++, du Fortran, du Python, du R etc... Donc, ça permet d'avoir dans un seul logiciel plein de possibilités de programmation.
- ♥ C'est gratuit. On peut pas faire plus cher que gratuit. Donc, c'est plutôt pratique.
- ♥ Il y a beaucoup de possibilités de personnalisation pour une expérience de programmation agréable au quotidien.

Vous comprendrez que cette sous-section est biaisée parce que je suis un fan de VS Code. Je n'ai jamais testé d'autres IDE que celui-là. Cependant, comme vous êtes jeunes, vous avez le droit d'être rebelles et si voulez tester autre chose, allez-y :). C'est à vos risques et périls ...

2.2.3 Installer Python via Anaconda

Windows

Mac

Linux (pour les lycéen(nes) fous/folles).

2.2.4 Environnement virtuel

Créer un environnement virtuel.

Installer des packages dans un environnement virtuel. Pour créer un environnement virtuel sur VS Code.

2.3 Bonus: Customiser VS Code avec des Plugins.

Quelques Plugins marrants: - vscode-pets - Icons -

2.4 Notions de base en Python

2.4.1 Les différents types de variables et les opérations en Python

2.4.2 Les conditions if, elif et else

2.4.3 Les boucles for et while

2.4.4 Données tabulées et Figures avec numpy et matplotlib

Montrer comment faire une figure pour une image. Montrer comment faire une figure pour des points de données (courbes) Montrer comment faire une figure en remplissant une zone avec un alpha.

Expliquer l'importance de checker la documentation.

3 M

ouvements philosophiques associés à l'IA Cybernétiques etc...

3.1 Histoire de l'IA

3.2 Fondements de l'apprentissage machine

3.2.1 Théoreme d'approximation universelle ou Théoreme de Cybenko: le pilier fondateur de l'apprentissage profond

3.2.2 Réseaux de neurones comme machines à apprendre des fonctions

3.2.3 Entraînement de réseaux de neurones: maximisation de la vraisemblance.

Fonction d'erreur définition comme negative log likelihood.

3.2.4 Régularisation et Hyperparameter tuning pour éviter le sur-ajustement et le sous-ajustement

Régularisation = prior on the weights

Yoshua Bengio.

Créateur des Gans Créateur des VAEs Créateur des Diffusion models.

Katie Bouman, Berthy Feng.

4 Mini-projets

4.1 Simulation d'un double pendule

On cherche à simuler un double pendule en utilisant le package `scipy` qui va nous permettre de résoudre un système d'équations différentielles de la forme

$$\omega_1 = \frac{d\theta_1}{dt} \quad (15)$$

$$\omega_2 = \frac{d\theta_2}{dt} \quad (16)$$

$$\frac{d\omega_1}{dt} = \frac{d^2\theta_1}{dt^2} = \dots \quad (17)$$

$$\frac{d\omega_2}{dt} = \frac{d^2\theta_2}{dt^2} = \dots \quad (18)$$

Ici, il nous reste à trouver les expressions des dernières équations. Comme je suis gentil, je vous les donne. Pour ceux qui sont intéressés je vous donne la dérivation complète en annexe.

Voici le système d'équations complets que vous devez simuler:

$$\begin{pmatrix} \omega_1 \\ \omega_2 \\ \dot{\omega}_1 \\ \dot{\omega}_2 \end{pmatrix} = \quad (19)$$

5 Projets

5.1 Inférence bayésienne d'images avec modèles de diffusion

5.2 Inférence bayésienne d'images avec normalizing flows

5.3 Transport optimal avec interpolant stochastique.

5.4 Apprentissage de distribution a priori sur Lénia

Bibliography